



INFORME DE MÉTRICAS Y AUDITORÍA TÉCNICA

Modelo XLM-RoBERTa para la Detección de Discurso de Odio y Toxicidad en Redes Sociales

Integrantes

Julio Enrique De La Quadra Mata
Cristian Antonio Escalante Hernández
Willian Alexander Chávez Servellón

Ciudad Universitaria, 25 de agosto de 2026

Índice

1. Configuración del Modelo y Esquema de Clases	1
2. Resultados de Evaluación de XLM-RoBERTa	1
2.1. Distribución del Corpus Experimental	1
2.2. Métricas Globales con Rigor Estadístico	2
2.3. Desempeño Desglosado por Clase	2
2.4. Matriz de Confusión Numérica	3
3. Análisis Cualitativo, Slices y Diagnóstico de Sesgos	4
3.1. Evaluación por Cortes (Slices) y Disparidad entre Plataformas	4
3.2. Sesgo Dialectal: Recalculación del FPR por Jerga Salvadoreña	5
4. Plan de Mitigación del Sesgo Dialectal	5
5. Conclusiones	6

Resumen

En el presente informe se presenta la evaluación experimental detallada del modelo **XLM-RoBERTa** ajustado para la clasificación multiclase de toxicidad y discurso de odio en publicaciones de redes sociales en El Salvador. Tras la aplicación de un plan de auditoría técnica integral (unificación de `max_length` = 128, corrección de variables de segmentación y deshardcodeo de tasas), el modelo alcanza una exactitud de 0.8109 y un F_1 -macro = 0,8100 [95 % CI: 0.7720, 0.8465] mediante estimación bootstrap. Se realiza un análisis en profundidad sobre las variaciones de rendimiento entre plataformas (X/Twitter con F_1 -macro = 0,8670 vs. Facebook con F_1 -macro = 0,7150) y se diagnostica un FPR real del 44,83 % ante la jerga regional.

1. Configuración del Modelo y Esquema de Clases

El modelo evaluado corresponde a la arquitectura Transformer multilingüe **XLM-RoBERTa** entrenada sobre el conjunto de datos recopilado. La tarea se definió como una clasificación en 4 categorías, mapeadas formalmente a través del parámetro de metadatos `id2label`:

Tabla 1: Esquema de Clases y Mapeo de Metadatos (`id2label`)

ID (<code>id2label</code>)	Clase Semántica	Definición Semántica
0	No Tóxico	Mensajes neutros, positivos o conversacionales estándar.
1	Lenguaje Ofensivo	Uso de improperios o vulgaridades no direccionadas a colectivos.
2	Discurso de Odio	Ataques sistemáticos o descalificaciones dirigidas a grupos vulnerables.
3	Amenazas / Violencia	Incitación directa a la violencia o agresiones físicas.

Asimismo, en el pipeline de tokenización e inferencia se unificó strictly la longitud máxima de secuencia a `max_length` = 128 tokens, corrigiendo las discrepancias observadas previamente en entornos de prueba.

2. Resultados de Evaluación de XLM-RoBERTa

2.1. Distribución del Corpus Experimental

A continuación se ilustra la distribución volumétrica de los datos empleados durante el pipeline de validación y prueba del modelo:




Figura 1: Distribución de frecuencias por clase en el conjunto experimental ($N = 3063$).

2.2. Métricas Globales con Rigor Estadístico

Sobre el conjunto de prueba ($n = 460$), el modelo XLM-RoBERTa alcanzó los siguientes resultados de rendimiento con precisión a 4 decimales e intervalos de confianza del 95 % mediante *bootstrapping* ($B = 2000$ re-muestreos):

Tabla 2: Métricas Globales de XLM-RoBERTa ($n = 460$)

Accuracy	Macro Precision	Macro Recall	Macro F1-Score	95 % CI (Macro F1)
0.8109	0.8102	0.8025	0.8100	[0.7720, 0.8465]

2.3. Desempeño Desglosado por Clase

Al analizar el comportamiento categoría por categoría con precisión de 4 decimales, se evidencia un desempeño balanceado a lo largo de todas las etiquetas:

Tabla 3: Métricas por Clase Obtenidas en el Test Set ($n = 460$)

Clase	Precision	Recall	F1-Score	Soporte (n)
No Tóxico	0.8636	0.7724	0.8155	123
Lenguaje Ofensivo	0.7824	0.8428	0.8115	159
Discurso de Odio	0.7879	0.8211	0.8041	95
Amenazas / Violencia	0.8077	0.7738	0.7904	83
Macro Avg	0.8102	0.8025	0.8100	460
Weighted Avg	0.8109	0.8109	0.8101	460




Figura 2: Desempeño por clase en XLM-RoBERTa (Precision, Recall y F1-Score a 4 decimales).

2.4. Matriz de Confusión Numérica

La evaluación del error revela una distribución donde las confusiones suceden primordialmente entre categorías contiguas. A continuación se presenta la matriz de confusión con conteos numéricos absolutos:

Tabla 4: Matriz de Confusión Numérica de Predicciones

Clase Real	Predicción del Modelo			
	No Tóxico	Ofensivo	Discurso Odio	Amenazas
No Tóxico	95	21	5	2
Lenguaje Ofensivo	11	134	10	4
Discurso de Odio	3	11	78	3
Amenazas / Violencia	1	5	13	64




Figura 3: Matriz de confusión numérica del modelo XLM-RoBERTa.

3. Análisis Cualitativo, Slices y Diagnóstico de Sesgos

3.1. Evaluación por Cortes (Slices) y Disparidad entre Plataformas

Tras la corrección y normalización de las variables `Presencia_Sarcasmo` y `Presencia_Ironia` (evaluando coincidencia sobre valores textuales ["SI", "SÍ"]), se determinaron las métricas exactas por plataforma de origen:




Figura 4: Evaluación del F1-macro según cortes sintáctico-semánticos y plataforma.

Al contrastar la procedencia de los datos, los resultados actualizados son:

- **Plataforma X (Twitter):** Registra un desempeño de $F_1\text{-macro} = 0,8670$. La concisión estructural y el lenguaje directo favorecen la extracción de representaciones densas en las capas del Transformer.

- **Plataforma Facebook:** Alcanza un F_1 -macro = 0,7150. La presencia de textos extensos, múltiples hilos conversacionales y sintaxis compleja degrada el rendimiento del modelo en esta plataforma.

3.2. Sesgo Dialectal: Recalculación del FPR por Jerga Salvadoreña

Se procedió a recalcular empíricamente la Tasa de Falsos Positivos (FPR), evaluando el impacto del caliche o jerga local sobre instancias neutras sin intencionalidad ofensiva.




Figura 5: Comparativa empírica real de la Tasa de Falsos Positivos (FPR) en textos neutros.

Los resultados recalculados confirman un sesgo pronunciado:

- **Texto Neutro sin Jerga:** FPR = 15,96 %.
- **Texto Neutro con Jerga Salvadoreña:** FPR = 44,83 %.

Esto demuestra una tendencia *systematic* a sobreclasificar expresiones coloquiales inofensivas como *Lenguaje Ofensivo*.

4. Plan de Mitigación del Sesgo Dialectal

Para resolver el desplazamiento de distribución de datos (*data distribution shift*) detectado en la auditoría, se aplicarán las siguientes acciones antes del reentrenamiento final:

1. **Aumento de Datos Dialectales (Data Augmentation):** Generación controlada de muestras sintéticas donde términos de jerga local se encuentren integrados en contextos puramente neutros o positivos.
2. **Regularización Anti-Sesgo (Debiasing Loss):** Incorporación de penalizaciones en la función de pérdida para desacoplar los tokens coloquiales regionales de la predicción de toxicidad.
3. **Adaptación MLM Dialectal:** Realizar un preentrenamiento secundario mediante Masked Language Modeling (MLM) sobre un corpus masivo de texto salvadoreño para enriquecer la semántica contextual del tokenizador y las capas superiores del modelo.

5. Conclusiones

1. El modelo XLM-RoBERTa demuestra una exactitud global de 0.8109 y un F_1 -macro = 0,8100 [95 % CI: 0.7720, 0.8465], con mejor desempeño en X ($F_1 = 0,8670$) que en Facebook ($F_1 = 0,7150$).
2. Se identificó empíricamente una tasa de falsos positivos del 44,83 % ante la presencia de jerga salvadoreña, frente al 15,96 % en texto estándar.