

Informe Técnico: Correcciones y Auditoría de Modelo XLM-RoBERTa

Proyecto de Clasificación de Texto
Universidad de El Salvador

26 de agosto de 2026

1. Resumen Informativo

En el presente documento se detalla el plan de correcciones aplicadas al pipeline de evaluación, procesamiento de métricas y control de versiones del modelo **XLM-RoBERTa**, luego de completar una auditoría técnica integral. Las modificaciones abordan inconsistencias metodológicas, errores de codificación en variables de prueba y la optimización del repositorio.

2. Desglose de Modificaciones y Justificación Técnica

Cuadro 1: Resumen del Estado de Auditoría

Item	Tarea Realizada	Severidad	Estado
1	Recalculación dinámica de FPR por jerga local	Crítica	Completado
2	Normalización de variables de sarcasmo/ironía	Crítica	Completado
3	Corrección de métricas reportadas por plataforma	Crítica	Completado
4	Unificación del parámetro <code>max_length = 128</code>	Alta	Completado
5	Integración de Bootstrap CI, Matriz Numérica y Precisión	Alta	Completado
6	Configuración explícita de <code>id2label</code>	Media	Completado
7	Depuración de Git y exclusión de artefactos pesados	Media	Completado

2.1. 1 y 3. Corrección de Métricas Reales (FPR y Plataforma)

Se eliminó la asignación estática (*hardcoded*) del False Positive Rate (FPR) por jerga local, sustituyendo los valores previos por los datos empíricos reales obtenidos durante la evaluación (15,96 % sin jerga y 44,83 % con jerga). Asimismo, se actualizaron los reportes de rendimiento por plataforma en la sección correspondiente, ajustando el F_1 -macro a 0,867 y 0,715 respectivamente.

2.2. 2. Estandarización de Etiquetas Slicing

Se corrigió la desalineación de nombres de columnas en las pruebas por cortes (*slices*). Las referencias obsoletas `Presencia_Sar` y `Presencia_Iro` fueron actualizadas a `Presencia_Sarcasmo` y `Presencia_Ironia`. Adicionalmente, se cambió la evaluación booleana rígida de enteros (1) por una función de normalización textual que valida explícitamente cadenas ["SI", "SÍ"].

2.3. 4. Unificación de Longitud de Secuencia

Se resolvió la discrepancia de dimensión en el tokenizador, fijando el límite `max_length = 128` en todo el pipeline (entrenamiento e inferencia), garantizando consistencia en el truncamiento y padding.

2.4. 5 y 6. Rigor Estadístico y Metadatos del Modelo

Para robustecer la evaluación:

- Se implementó la estimación de intervalos de confianza al 95 % mediante *bootstrapping* ($n = 2000$) sobre la métrica F_1 -macro.
- Se configuró la exportación de métricas tabulares con precisión fija a 4 decimales y visualizaciones con etiquetas absolutas en la Matriz de Confusión.
- Se vinculó el diccionario `id2label` con los nombres semánticos de las clases durante la instanciación de la arquitectura.

2.5. 7. Depuración del Control de Versiones

Se reestructuró la gestión de Git mediante la inclusión de reglas globales y locales en `.gitignore`. Se extrajeron del árbol de seguimiento los pesos binarios (`.safetensors`, `.bin`), entornos virtuales (`venv/`), datasets pesados (`.csv`) y checkpoints de entrenamiento (`results_xlmr/`), ejecutando el desacople mediante `git rm -r --cached`.

3. Conclusión

El pipeline de inferencia y evaluación ha sido estandarizado satisfactoriamente, corrigiendo los sesgos de reporte y garantizando un entorno de control de versiones limpio, preparado para la fase final de reentrenamiento.