



INFORME DE MÉTRICAS

Modelo XLM-RoBERTa para la Detección de Discurso de Odio y Toxicidad en Redes Sociales

Integrantes

Julio Enrique De La Quadra Mata
Cristian Antonio Escalante Hernández
Willian Alexander Chávez Servellón

Ciudad Universitaria, 6 de agosto de 2026

Índice

1. Configuración del Modelo y Esquema de Clases	1
2. Resultados de Evaluación de XLM-RoBERTa	1
2.1. Distribución del Corpus Experimental	1
2.2. Métricas Globales	2
2.3. Desempeño Desglosado por Clase	2
2.4. Matriz de Confusión y Análisis de Error Ordinal	2
3. Análisis Cualitativo, Slices y Diagnóstico de Sesgos	3
3.1. Evaluación por Cortes (Slices) y Disparidad entre Plataformas	3
3.2. Sesgo Dialectal: Jerga Salvadoreña y Falsos Positivos	4
4. Plan de Mitigación del Sesgo Dialectal	4
5. Conclusiones	5

Resumen

En el presente informe se presenta la evaluación experimental detallada del modelo **XLM-RoBERTa** ajustado para la clasificación multiclase de toxicidad y discurso de odio en publicaciones de redes sociales en El Salvador. Si bien el modelo alcanza un desempeño global sólido (F_1 -macro = 0,81), se realiza un análisis en profundidad sobre las variaciones de rendimiento entre plataformas (X/Twitter vs. Facebook) y se identifica un sesgo sistemático hacia la jerga regional salvadoreña. Finalmente, se proponen estrategias concretas para la mitigación de estos fallos en futuras iteraciones.

1. Configuración del Modelo y Esquema de Clases

El modelo evaluado corresponde a la arquitectura Transformer multilingüe **XLM-RoBERTa** entrenada sobre el conjunto de datos recopilado. La tarea se definió como una clasificación en 4 categorías:

Tabla 1: Esquema de Clases para Evaluación de XLM-RoBERTa

Etiqueta	Clase	Definición Semántica
0	No Tóxico	Mensajes neutros, positivos o conversacionales estándar.
1	Lenguaje Ofensivo	Uso de improperios o vulgaridades no direccionadas a colectivos.
2	Discurso de Odio	Ataques sistemáticos o descalificaciones dirigidas a grupos vulnerables.
3	Amenazas / Violencia	Incitación directa a la violencia o agresiones físicas.

2. Resultados de Evaluación de XLM-RoBERTa

2.1. Distribución del Corpus Experimental

A continuación se ilustra la distribución volumétrica de los datos empleados durante el pipeline de validación y prueba del modelo:




Figura 1: Distribución de frecuencias por clase en el conjunto experimental ($N = 3063$).

2.2. Métricas Globales

Sobre el conjunto de prueba ($n = 460$), el modelo XLM-RoBERTa alcanzó un desempeño general de 0.81 en exactitud y macro-promedio de F1:

Tabla 2: Métricas Globales de XLM-RoBERTa ($n = 460$)

Accuracy	Macro Precision	Macro Recall	Macro F1-Score
0.81	0.81	0.80	0.81

2.3. Desempeño Desglosado por Clase

Al analizar el comportamiento categoría por categoría, se observa la precisión más alta en la clase *No Tóxico* (0.86) y un balance sólido en las categorías de mayor severidad:

Tabla 3: Métricas por Clase Obtenidas en el Test Set

Clase	Precision	Recall	F1-Score	Soporte (n)
No Tóxico	0.86	0.77	0.82	123
Lenguaje Ofensivo	0.78	0.84	0.81	159
Discurso de Odio	0.79	0.82	0.80	95
Amenazas / Violencia	0.81	0.78	0.80	83
Macro Avg	0.81	0.80	0.81	460
Weighted Avg	0.81	0.81	0.81	460




Figura 2: Desempeño por clase en XLM-RoBERTa (Precision, Recall y F1-Score).

2.4. Matriz de Confusión y Análisis de Error Ordinal

La matriz de confusión refleja que la mayoría de las predicciones correctas se ubican en la diagonal principal. Las confusiones registradas ocurren primordialmente entre clases adyacentes (como *Lenguaje Ofensivo* y *Discurso de Odio*), lo que indica que el modelo comprende la gradación del nivel de agresión, minimizando los errores de severidad extrema.




Figura 3: Matriz de confusión del modelo XLM-RoBERTa.

3. Análisis Cualitativo, Slices y Diagnóstico de Sesgos

3.1. Evaluación por Cortes (Slices) y Disparidad entre Plataformas

A través de las variables auxiliares del corpus, se evaluó la estabilidad del modelo frente a diferentes entornos de origen y características lingüísticas.




Figura 4: Evaluación del F1-macro según cortes sintáctico-semánticos y plataforma.

Al contrastar el origen de los datos, se evidencia un comportamiento diferenciado:

- **Plataforma X (Twitter):** Presenta un margen de error mínimo (F_1 -macro $\approx 0,85$). La concisión del texto y la estructura directa de las publicaciones facilitan la extracción de características por parte de las capas de atención del Transformer.

- **Plataforma Facebook:** Registra una tasa de error significativamente superior (F_1 -macro $\approx 0,69$). Esto se debe a la mayor longitud de los comentarios, el uso de sintaxis desestructurada, múltiples hilos narrativos en un solo mensaje y la presencia de ironía implícita.

3.2. Sesgo Dialectal: Jerga Salvadoreña y Falsos Positivos

Un hallazgo crítico en la evaluación radica en cómo el modelo procesa el léxico regional salvadoreño (caliche o modismos locales no peyorativos). XLM-RoBERTa tiende a asociar de forma directa la presencia de términos de jerga con contenido hostil, clasificándolos erróneamente como *Lenguaje Ofensivo*.




Figura 5: Comparativa de la Tasa de Falsos Positivos (FPR) en textos neutros con y sin jerga salvadoreña.

Como se ilustra en la Figura 5, cuando un texto neutro utiliza léxico estándar, la Tasa de Falsos Positivos (FPR) es de apenas 14.2 %. Sin embargo, al incluir modismos regionales en contextos completamente inofensivos, el FPR se dispara al 38.5 %.

4. Plan de Mitigación del Sesgo Dialectal

Este problema no representa una limitación insuperable de la arquitectura, sino un sesgo de distribución en los datos de entrenamiento (*data distribution shift*). Para corregir esta asociación espuria en versiones futuras, se proponen las siguientes soluciones:

1. **Aumento de Datos Específico (Data Augmentation):** Sintetizar e incorporar ejemplos donde modismos locales aparezcan en contextos marcadamente positivos o neutros.
2. **Técnicas de Unlearning y Regularización:** Aplicar pérdida por desambiguación (*Debiasing Loss*) durante el ajuste fino para penalizar la ponderación excesiva de tokens coloquiales en ausencia de intencionalidad ofensiva.
3. **Preentrenamiento Dialectal Secundario:** Realizar una fase intermedia de Masked Language Modeling (MLM) utilizando un corpus local salvadoreño para adecuar los embeddings contextuales de XLM-RoBERTa al dialecto regional.

5. Conclusiones

1. El modelo XLM-RoBERTa demuestra un desempeño global sobresaliente ($F_1 = 0,81$), exhibiendo su mayor eficacia en mensajes breves provenientes de la plataforma X.
2. La mayor tasa de fallo en Facebook y la sobreclasificación de falsos positivos ante la jerga local son áreas identificadas de mejora, cuya solución técnica es viable mediante el enriquecimiento dialectal del conjunto de datos y la regulación del sesgo.